# 회귀 기법 Regression Techniques

이건명 충북대학교 소프트웨어학과


### 학습 내용

- 선형 회귀를 위한 학습 알고리즘으로 경사 하강법에 대해서 알아본다. .
- 선형 회귀의 목적함수를 변형한 리지 회귀, 라소 회귀, 일래스틱 회귀에 대해서 알아본다.
- 이상치가 많은 데이터에 대한 회귀 기법인 RANSAC에 대해서 알아본다.
- 단조 함수 형태를 근사하는 이소토닉 회귀에 대해서 알아본다.
- 비선형인 형태의 함수를 근사하는 다항 회귀에 대해서 알아본다.
- 서포트 벡터 머신의 개념을 적용한 서포트 벡터 회귀에 대해서 알아본다.

# 1. 선형 회귀

- ❖ 회귀 (regression)
  - **학습 데이터에 부합**되는 **출력**값이 **실수**인 함수를 찾는 문제
- ❖ 선형회귀(linear regression)
  - 선형 함수  $f(x) = a_0 + a_1x_1 + a_2x_2 + \dots + a_mx_n$ 을 사용한 함수 근사

$$f^*(x) = \operatorname{arg\,min}_f \sum_{i=1}^n (\mathbf{y_i} - \mathbf{f}(\mathbf{x_i}))^2$$



기계학습, 이건명


# 선형회귀


#### ❖ 학습방법

- 경사 하강법
  - 학습 데이터에 부합되는 출력값이 되도록 파라미터 변경하는 일

$$E = \frac{1}{2} \sum_{i} (y_i - f(x_i))^2$$

$$\nabla E = \left(\frac{\partial E}{\partial a}, \frac{\partial E}{\partial b}\right)$$





$$a^{(t+1)} \leftarrow a^{(t)} - \eta \nabla_a$$

# 선형회귀

#### ❖ 학습방법

■ 선형회귀의 경사 하강법

$$E = \frac{1}{2} \sum_{i} (y_i - f(\mathbf{x}_i))^2$$

$$f(\mathbf{x}_i) = \mathbf{w}_0 + \mathbf{w}_1 \mathbf{x}_{i1} + \mathbf{w}_2 \mathbf{x}_{i2} + \dots + \mathbf{w}_n \mathbf{x}_{in}$$

$$\frac{\partial E}{\partial \mathbf{w}_k} = -\sum_{i} (y_i - f(\mathbf{x}_i)) \mathbf{x}_{ik}$$

$$\frac{\partial E}{\partial \mathbf{w}_0} = -\sum_{i} (y_i - f(\mathbf{x}_i))$$

```
w_k \leftarrow w_k - \eta \frac{\partial E}{\partial w_k} w_0 \leftarrow w_0 - \eta \frac{\partial E}{\partial w_0}
```

```
def fit(self, X, y):
    self.w_ = np.zeros(1+X.shape[1])
    self.cost_ = [ ]

for i in range(self.n_iter):
    output = self.net_input(X)
    errors = (y - output)
    self.w_[1:] += self.eta*X.T.dot(errors)
    self.w_[0] += self.eta * errors.sum()
    cost = (errors**2).sum()/2.0
    self.cost_.append(cost)
    return self
```

### ❖ [실습] 경사하강법에 의한 선형회귀 학습

return self.net\_input(X)


```
import pandas as pd
import numpy as np
                                                      from sklearn.datasets import load boston
class LinearRegressionGD(object):
                                                      from sklearn.model_selection import train_test_split
   def init (self, eta=0.001, n iter=20):
                                                      from sklearn.preprocessing import StandardScaler
      self.eta = eta
      self.n iter = n iter
                                                      boston = load boston()
                                                      data = pd.DataFrame(boston.data,
   def fit(self, X, y):
                                                                  columns=boston.feature names)
      self.w_ = np.zeros(1+X.shape[1])
                                                      print(data.head())
      self.cost_ = [ ]
                                                      print(y[0:5])
      for i in range(self.n iter):
                                                      X = data[['RM', 'PTRATIO']].values
                                                      v = boston.target
         output = self.net input(X)
         errors = (y - output)
         self.w [1:] += self.eta*X.T.dot(errors)
         self.w [0] += self.eta * errors.sum()
                                                        ZN INDUS CHAS NOX ... RAD TAX PTRATIO
                                                  CRIM
                                                                                                        B LSTAT
         cost = (errors**2).sum()/2.0
                                                 0 0.00632 18.0 2.31 0.0 0.538 ... 1.0 296.0
                                                                                            15.3 396.90 4.98
                                                 1 0.02731 0.0 7.07 0.0 0.469 ... 2.0 242.0
                                                                                            17.8 396.90 9.14
         self.cost_.append(cost)
                                                 2 0.02729 0.0 7.07 0.0 0.469 ... 2.0 242.0
                                                                                            17.8 392.83 4.03
      return self
                                                 3 0.03237 0.0 2.18 0.0 0.458 ... 3.0 222.0
                                                                                            18.7 394.63 2.94
                                                           0.0 2.18 0.0 0.458 ... 3.0 222.0
                                                                                            18.7 396.90 5.33
                                                 4 0.06905
   def net input(self, X):
      return np.dot(X, self.w_[1:]) + self.w_[0]
                                                  [24. 21.6 34.7 33.4 36.2]
   def predict(self, X):
```

```
sc_x = StandardScaler()
sc_y = StandardScaler()
X_std = sc_x.fit_transform(X)
y_std = sc_y.fit_transform(y[:,np.newaxis]).flatten()
X_train, X_test, y_train, y_test = train_test_split(X_std, y_std, test_size=0.2, random_state=123)
```

Ir = LinearRegressionGD( )
Ir.fit(X\_train, y\_train)

import matplotlib.pyplot as plt
plt.plot(range(1, lr.n\_iter+1), lr.cost\_)
plt.ylabel('Sum of Squared Error')
plt.xlabel('Iterations')
plt.show()

from sklearn.metrics import mean\_squared\_error
preds = Ir.predict(X\_test)
mse = mean\_squared\_error(y\_test,preds)
print('Root mean squared error : ', np.sqrt(mse))



Root mean squared error: 0.7389665258932069


# 2. 리지 회귀

- ❖ 리지 회귀(ridge regression, 능형회귀)
  - 가중치의 L2-노름을 벌점을 손실함수에 추가

$$L2: \|\mathbf{w}\|_2^2 = \sum_{i=1}^n w_i^2$$

목적함수 = 
$$MSE(\boldsymbol{w}) + \alpha \frac{1}{2} \|\boldsymbol{w}\|_2^2$$

■ 과적합 회피에 도움



#### Ridge (능선)



$$f(x_i) = w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_n x_{in}$$
$$w = (w_0, w_1, \dots w_n)$$


### 3. 라소 회귀

- ❖ 라소 회귀(Lasso regression)
  - 가중치 L1-노름을 벌점으로 손실함수에 추가


$$L1: \|\mathbf{w}\|_1 = \sum_{i=1}^n |w_i|$$

목적함수 = 
$$MSE(\mathbf{w}) + \alpha \|\mathbf{w}\|_1$$

■ 리지 회귀보다 단순한 모델 생성 가능




Lasso (least absolute shrinkage and selection operator)



### 4. 일래스틱 넷

- ❖ 일래스틱 넷(Elastic Net)
  - 가중치의 L1-노름과 L2-노름을 벌점으로 손실함수에 추가

목적함수 = 
$$MSE(\boldsymbol{w}) + \gamma \alpha \|\boldsymbol{w}\|_1 + \frac{1-\gamma}{2} \alpha \|\boldsymbol{w}\|_2^2$$



### ❖ [실습] 선형회귀, 리지 회귀, 라소 회귀, 일레스틱 넷 기반 회귀

```
import numpy as np
import pandas as pd
from sklearn.datasets import load boston
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression, Ridge, Lasso, ElasticNet
from sklearn.metrics import mean squared error
boston = load boston()
data = pd.DataFrame(boston.data,columns=boston.feature names)
X = data[['RM', 'PTRATIO', 'RAD', 'TAX', 'LSTAT', 'CRIM', 'NOX', 'B']].values
y = boston.target
sc_x = StandardScaler()
sc_y = StandardScaler()
X_{std} = sc_x.fit_{transform}(X)
y_std = sc_y.fit_transform(y[:,np.newaxis]).flatten()
X_train, X_test, y_train, y_test = train_test_split(X_std, y_std, test_size=0.2, random_state=123)
linear = LinearRegression()
ridge = Ridge(alpha=1.0, random_state=0)
lasso = Lasso(alpha=1.0, random_state=0)
enet = ElasticNet(alpha=1.0, l1_ratio=0.5)
linear.fit(X_train, y_train)
ridge.fit(X_train, y_train)
lasso.fit(X_train, y_train)
enet.fit(X_train, y_train)
```

```
linear_pred = linear.predict(X train)
ridge_pred = ridge.predict(X_train)
lasso pred = lasso.predict(X train)
enet_pred = enet.predict(X_train)
print('Linear - RMSE for training data: ', np.sqrt(mean_squared_error(y_train, linear_pred)))
print('Ridge - RMSE for training data: ', np.sqrt(mean_squared_error(y_train, ridge_pred)))
print('Lasso - RMSE for training data: ', np.sqrt(mean_squared_error(y_train, lasso_pred)))
print('Elastic Net - RMSE for training data: ', np.sqrt(mean_squared_error(y_train, enet_pred)))
linear pred = linear.predict(X test)
ridge_pred = ridge.predict(X_test)
lasso pred = lasso.predict(X test)
enet_pred = enet.predict(X_test)
print('\text{\text{\text{W}nLinear}} - RMSE for test data: ', np.sqrt(mean_squared_error(y_test, linear_pred)))
print('Ridge - RMSE for test data: ', np.sqrt(mean_squared_error(y_test, ridge_pred)))
print('Lasso - RMSE for test data: ', np.sqrt(mean_squared_error(y_test, lasso_pred)))
print('Elastic Net - RMSE for test data: ', np.sqrt(mean_squared_error(y_test, enet_pred)))
           Linear - RMSE for training data: 0.527646292874511
           Ridge - RMSE for training data: 0.5276524376179831
           Lasso - RMSE for training data: 1.0017823143577615
           Elastic Net - RMSE for training data: 0.8463715147933433
           Linear - RMSE for test data: 0.6299606779044659
           Ridge - RMSE for test data: 0.6299657952065147
```


Lasso - RMSE for test data: 0.9936481587307943

Elastic Net - RMSE for test data: 0.8578764629897222

### 5. RANSAC 방법

#### ❖ RANSAC(RANdom Sample Consensus) 방법

■ 데이터를 **인라이어**(inlier, **정상치**)와 **아웃라이어**(outlier, **이상치**)로 구분해 회 귀 과정을 반복 수행



- 1. 무작위로 일부 데이터를 정상치로 선택하여 모델 학습
- 2. 학습된 모델에 대해 다른 모든 데이터 테스트. **허용오차 이내의 데이터** 를 정상치로 추가
- 3. 모든 정상치 데이터를 사용하여 모델 재학습
- 4. 학습된 모델에 대한 정상치 데이터의 오차 계산
- 5. 오차가 임계값 이내이거나 지정된 반복회수에 도달하면 종료. 아니면 단계 1로 돌아감

### ❖ [실습] RANSAC 기반 선형회귀

plt.show()

```
import numpy as np
import pandas as pd
from sklearn.datasets import load boston
import matplotlib.pyplot as plt

from sklearn.linear_model import RANSACRegressor, LinearRegression


boston = load_boston()

data = pd.DataFrame(boston.data,columns=boston.feature_names)
                                                                                   30
data = pd.DataFrame(boston.data,columns=boston.feature names)
print(data.head( ))
X = data[['RM']].values
                                                                                   -10
y = boston.target
                                                                                                 Average number of rooms [RM]
ransac = RANSACRegressor(LinearRegression(), max trials=100, min samples=50,
                      loss='absolute_loss', residual_threshold=5.0, random_state=0)
ransac.fit(X,y)
inlier mask = ransac.inlier mask
outlier_mask = np.logical_not(inlier_mask)
line X = np.arange(3,10,1)
line y ransac = ransac.predict(line X[:, np.newaxis])
plt.scatter(X[inlier_mask], y[inlier_mask], c='steelblue', edgecolor='white', marker='o', label='Inliers')
plt.scatter(X[outlier_mask], y[outlier_mask], c='limegreen', edgecolor='white', marker='s', label='Outliers')
plt.plot(line_X, line_y_ransac, color='black', lw=2)
plt.xlabel('Average number of rooms [RM]')
plt.ylabel('Price in $1000s [MEDV]')
plt.legend(loc='upper left')
```

# 6. 이소토닉 회귀


### ❖ 이소토닉 회귀(Isotonic Regression)

- 비감소(non-decreasing) 또는 비증가(non-increasing) 함수 회귀
- 상세한 변화 표현
- 대상 함수를 최소화하는 부분 보간 함수 사용



#### ❖ [실습] 이소토닉 회귀

```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.collections import LineCollection
from sklearn.linear_model import LinearRegression
from sklearn.isotonic import IsotonicRegression
from sklearn.utils import check random state
n = 100
x = np.arange(n)
rs = check random state(0)
y = rs.randint(-50, 50, size=(n,)) + 50. * np.log1p(np.arange(n))
ir = IsotonicRegression()
y_{-} = ir.fit_{transform}(x, y)
lr = LinearRegression( )
                                                             250
lr.fit(x[:, np.newaxis], y)
                                                             200
segments = [[[i, y[i]], [i, y_[i]]]] for i in range(n)]
lc = LineCollection(segments, zorder=0)
                                                             150
lc.set_array(np.ones(len(y)))
lc.set_linewidths(np.full(n, 0.5))
                                                             100
fig = plt.figure()
                                                              50
plt.plot(x, y, 'r.', markersize=10)
plt.plot(x, y_, 'b.-', markersize=10)
                                                               0
plt.plot(x, lr.predict(x[:, np.newaxis]), g-')
plt.gca().add_collection(lc)
plt.legend(('Data', 'Isotonic Fit', 'Linear Fit'), loc='lower right')
plt.title('Isotonic regression')
plt.show()
```





# 7. 다항회귀

### ❖ 다항회귀(polynomial regression)

- 기존 변수들을 이용하여 계산한 여분의 변수를 추가한 선형회귀
- 비선형 형태의 함수 근사
- 예.

• 
$$x = (x_1, x_2) \rightarrow x' = (x_1, x_2, x_1x_2, x_1^2, x_2^2)$$





#### ❖ [실습] 다항 회귀

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import Ridge
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import make_pipeline
```


```
def f(x):
   return x * np.sin(x)
x_plot = np.linspace(0, 10, 100)
x = np.linspace(0, 10, 100)
rng = np.random.RandomState(0)
rng.shuffle(x)
                                                                -5
x = np.sort(x[:20])
y = f(x)
                                                                       around truth
                                                               -10
                                                                       degree 3
X = x[:, np.newaxis]
                                                                       degree 4
X_plot = x_plot[:, np.newaxis]
                                                                       degree 5
                                                                       training points
                                                               -15
colors = ['teal', 'yellowgreen', 'gold']
                                                                                              6
lw = 2
plt.plot(x_plot, f(x_plot), color='cornflowerblue', linewidth=lw, label="ground truth")
plt.scatter(x, y, color='navy', s=30, marker='o', label="training points")
for count, degree in enumerate([3, 4, 5]):
   model = make_pipeline(PolynomialFeatures(degree), Ridge())
   model.fit(X, y)
   y_plot = model.predict(X_plot)
   plt.plot(x plot, y plot, color=colors[count], linewidth=lw, label="degree %d" % degree)
plt.legend(loc='lower left')
plt.show()
```

8

10

### 8. 서포트 벡터 회귀

- ❖ 서포트 벡터 회귀(SVR, Support Vector Regression)
  - 예측값이 목푯값을 중심으로 반지름이 엡실론(ε, 기본값 0.1)인 볼(ball) 에 포함되면 패널티 미적용
  - 학습 데이터 : {(x<sub>1</sub>, y<sub>1</sub>), (x<sub>2</sub>, y<sub>2</sub>), ···, (x<sub>l</sub>, y)}



차이  $y_i - \mathbf{w}_i \cdot \mathbf{x}_i$ 가  $\epsilon$ 이내이면, 오차가 없는 것으로 간주

# **Support Vector Regression**

#### ❖ 서포트 벡터 회귀(SVR)

- 예측값이 목푯값을 중심으로 반지름이 엡실론(ε, 기본값 0.1)인 볼(ball)
   에 포함되면 패널티 미적용
- 학습 데이터 : {(x<sub>1</sub>, y<sub>1</sub>), (x<sub>2</sub>, y<sub>2</sub>), ···, (x<sub>l</sub>, y)}

minimize 
$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} (\xi_i + \xi_i^*)$$
subject to 
$$\begin{cases} y_i - \langle w, x_i \rangle - b \le \varepsilon + \xi_i \\ \langle w, x_i \rangle + b - y_i \le \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \ge 0 \end{cases}$$

$$L := \frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} (\xi_i + \xi_i^*) - \sum_{i=1}^{\ell} (\eta_i \xi_i + \eta_i^* \xi_i^*)$$
$$- \sum_{i=1}^{\ell} \alpha_i (\varepsilon + \xi_i - y_i + \langle w, x_i \rangle + b)$$
$$- \sum_{i=1}^{\ell} \alpha_i^* (\varepsilon + \xi_i^* + y_i - \langle w, x_i \rangle - b)$$

#### ❖ [실습] SVR 적용 회귀


```
from sklearn.svm import SVR import matplotlib.pyplot as plt import numpy as np

X = np.sort(5 * np.random.rand(40, 1), axis=0)
y = np.sin(X).ravel()
y[::5] += 3 * (0.5 - np.random.rand(8)) # 잡음 추가

svr_rbf = SVR(kernel='rbf', C=100, gamma=0.1, epsilon=.1)
svr_lin = SVR(kernel='linear', C=100, gamma='auto')
svr_poly = SVR(kernel='poly', C=100, gamma='auto', degree=3, epsilon=.1, coef0=1)

lw = 2
svrs = [svr_rbf, svr_lin, svr_poly]
kernel_label = ['RBF', 'Linear', 'Polynomial']
model color = ['m', 'c', 'q']
```

fig.text(0.5, 0.04, 'data', ha='center', va='center')
fig.text(0.06, 0.5, 'target', ha='center', va='center', rotation='vertical')
fig.suptitle("Support Vector Regression", fontsize=14)
plt.show( )



### Quiz

- 1. 리지 회귀가 라소 회귀보다 더 단순한 모델을 학습할 가능성이 높다. (O,X)
- 2. RANSAC은 이상치가 많은 데이터 집합에 대한 회귀에 적용할 수 있다. (O,X)
- 3. SVR은 목표 함수에서 일정 거리 이내 만큼 떨어진 데이터에 대해 서는 오차가 없는 것으로 간주한다. (O,X)
- 4. 선형 회귀를 통해서는 비선형인 형태의 함수를 학습할 수 없다. (O,X)
- 5. 이소토닉 회귀를 사용하면 선형 회귀에서 보다 지역적인 변화를 민 감하게 확인할 수 있다. (O,X)
- 6. 일래스틱넷 모델은 항상 리지 회귀보다 좋은 결과를 보여준다. (O,X)