신경망 - 1 Neural Networks


이건명 충북대학교 소프트웨어학과

학습 내용

- 신경망을 구성하는 뉴런의 함수적 특성을 이해한다.
- 퍼셉트론 모델의 특성을 알아본다.
- 다층 퍼셉트론에 대해서 알아본다.
- 미분 방법에 대해서 복습한다.
- 다층 퍼셉트론의 학습 알고리즘인 오차 역전파 알고리즘에 대해 알아본다.

1. 신경망

- ❖ 신경망(neural network, artificial neural network)
 - 인간 두뇌에 대한 계산적 모델을 통해 인공지능을 구현하려는 분야
 - 신경세포 (neuron)




신경세포 8.6 × 10¹⁰ 개 신경연접 1.5 × 10¹⁴ 개

- 수상돌기(樹狀突起, dendrite): 다른 신경세포의 축색돌기와 연결되어 전기화학적 신호를 받아들이는 부위
- 축색돌기(軸索突起, axon): 수신한 전기화학적 신호의 합성결과 값이 특정 임계값이 이상이면 신호를 내보는 부위.
- **신경연접**(神經連接, synapse) : 수상돌기와 축색돌기 연결 부위
 - 전달되는 신호의 증폭 또는 감쇄

2. 퍼셉트론


❖ 신경세포의 계산 모델

■ 신경세포



McClulloch & Pitts, 1943 신경세포의 계산 모델


- 퍼셉트론(Perceptron)
 - 로젠블랏(Rosenblatt, 1957)이 제안한 학습가능한 신경망 모델



2. 퍼셉트론

❖ 신경세포의 계산 모델


■ 퍼셉트론(Perceptron)




```
def Perceptron(inputs):
    sum = np.dot(inputs, weights[1:]) + weights[0]
    if sum > 0:
        activation = 1
    else:
        activation = 0
    return activation
```

퍼셉트론

- **❖ 퍼셉트론**(Perceptron)
 - OR 연산을 수행하는 퍼셉트론




$$y = f(s) = f(\sum_{i=1}^{2} w_i x_i + b) = f(\mathbf{w}^{\top} \mathbf{x}) = x_1 + x_2 - 0.5$$




퍼셉트론

- **❖ 퍼셉트론**(Perceptron)
 - 선형 분리가능 문제 (linearly separable problem)



- 선형 분리불가 문제(linearly inseparable problem)
 - XOR(exclusive OR) 문제



(0,0):0


(0,1):1


(1,0):1


(1,1):0

3. 다층 퍼셉트론

- ❖ 다층 퍼셉트론(multilayer Perceptron, **MLP**)
 - 여러 개의 퍼셉트론을 층 구조로 구성한 신경망 모델









$$y = f(s) = f(\sum_{i=1}^{2} w_i x_i + b) = f(\mathbf{w}^{\top} \mathbf{x})$$

- ❖ 다층 퍼셉트론(multilayer Perceptron, MLP) cont.
 - 다층 퍼셉트론의 학습
 - 입력-출력 (x_i, y_i) 의 학습 데이터에 대해서, 기대출력 y_i 와 다층 퍼셉트론의 출력 $f(x_i)$ 의 차이, 즉 **오차**(error)가 최소가 되도록 **가중치 w**를 **결정**하는 것
 - 학습 가능한 다층 퍼셉트론
 - 오차 역전파(error backpropagation) 알고리즘
 - 활성화 함수를 계단 함수에서 미분가능한 시그모이드 함수로 대체
 - 경사 하강법 적용






시그모이드(sigmoid) 함수

- ❖ 활성화 함수(activation function)
 - 계단 (step) 함수

```
def step(x):
    if x > 0:
        return 1
    else:
        return 0
```



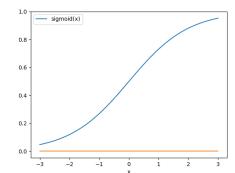
- 시그모이드(sigmoid) 함수
 - 구간 (0,1)의 출력 def sigmoid(x, a=1): return 1/(1+np.exp(-a*x))


$$\sigma(x,a) = \frac{1}{1 + e^{-ax}}$$


def d_sigmoid(x, a=1):

$$\sigma'(x,a) = a\sigma(x,a)(1 - \sigma(x,a)$$

return a*sigmoid(x,a)*(1 - sigmoid(x,a))










- ❖ 활성화 함수(activation function) cont.
 - 쌍곡탄젠트(tanh) 함수
 - 구간 (-1, 1)의 출력

$$\tanh(x) = \frac{e^{2x} - 1}{e^{2x} + 1}$$


$$\tanh'(x) = 1 - \tanh^2(x)$$








❖ 다층 퍼셉트론 MLP의 동작




$$ightharpoonup o_1$$
 입력 $(x_1, x_2, \, \cdots, x_d)$ 출력 $(y_1, y_2, \, \cdots, y_m)$

윤닉층
$$zsum_j=\sum_{i=1}^d u_{ji}x_i+u_{j0}\quad (1\leq j\leq p)$$

$$z_j=f(zsum_j)$$
 출력층 $osum_k=\sum_{j=1}^p v_{jk}z_k+v_{0k}\quad (1\leq k\leq m)$ $o_k=f(osum_k)$



❖ 다층 퍼셉트론(MLP)의 학습



입력: $(x_1, x_2, ..., x_d)$

기대 출력 : y_k

MLP 출력 : o_k

■ 학습 목표

• 기대 출력과 MLP 출력이 최대한 비슷해지도록 가중치를 변경하는 것

$$E = \frac{1}{2}(o_k - y_k)^2$$

• 경사 하강법(gradient descent method) 사용

$$v_{jk}^{(t+1)} = v_{jk}^{(t)} - \eta \frac{\partial E}{\partial v_{jk}}$$

$$u_{ij}^{(t+1)} = u_{ij}^{(t)} - \eta \frac{\partial E}{\partial u_{ij}}$$

4. 미분

❖ **미분**(differentiation, 微分)

=4x

- 함수 f(x)의 변수 x에 대한 순간변화율
- x의 아주 미세한 변화에 대한 f(x)의 변화량

$$f'(x) = \frac{df(x)}{dx} = \lim_{\Delta x \to 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

• 이네)
$$f(x) = 2x^2 + 1$$

$$f'(x) = \lim_{\Delta x \to 0} \frac{2(x + \Delta x)^2 + 1 - 2x^2 - 1}{\Delta x}$$

$$= \lim_{\Delta x \to 0} \frac{2x^2 + 4x\Delta x + (\Delta x)^2 + 1 - 2x^2 - 1}{\Delta x}$$

$$= \lim_{\Delta x \to 0} \frac{4x\Delta x + (\Delta x)^2}{\Delta x}$$

$$= \lim_{\Delta x \to 0} (4x + \Delta x)$$

■ 상수 미분
$$\frac{d}{dx}c=0$$

■ 거듭제곱 미분
$$\frac{d}{dx}x^n = n x^{n-1}$$

■ 지수함수의 미분
$$\frac{de^{ax}}{dx} = ae^{ax}$$

■ 로그함수의 미분
$$\frac{d \log x}{dx} = \frac{1}{x}$$

• 상수배의 미분
$$\frac{d}{dx}[cf(x)] = c\frac{d}{dx}f(x)$$

• 합의 미분
$$rac{d}{dx}[f(x)+g(x)]=rac{d}{dx}f(x)+rac{d}{dx}g(x)$$

• 곱의 미분
$$\frac{d}{dx}[f(x)g(x)] = g(x)\frac{d}{dx}f(x) + f(x)\frac{d}{dx}g(x)$$

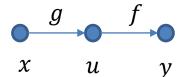
• 분수식의 미분
$$\frac{d}{dx}\left(\frac{f(x)}{g(x)}\right) = \frac{g(x) f'(x) + f(x) g'(x)}{(g(x))^2}$$

• 연쇄 법칙(Chain Rule)

 $= \frac{dy}{du} \frac{du}{dx}$

$$y = f(g(x))$$
$$y = f(u), \qquad u = g(x)$$

$$\frac{dy}{dx} = \frac{dy}{du}\frac{du}{dx}$$



$$\frac{\Delta y}{\Delta x} = \frac{\Delta y}{\Delta u} \frac{\Delta u}{\Delta x}$$

$$\frac{dy}{dx} = \lim_{\Delta x \to 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \to 0} \left(\frac{\Delta y}{\Delta u} \frac{\Delta u}{\Delta x} \right) = \left[\lim_{\Delta x \to 0} \frac{\Delta y}{\Delta u} \right] \left[\lim_{\Delta x \to 0} \frac{\Delta u}{\Delta x} \right]$$

$$\Delta x \to 0 \text{ 이면, } \Delta u \to 0 \text{ 이므로}$$


$$= \left[\lim_{\Delta u \to 0} \frac{\Delta y}{\Delta u} \right] \left[\lim_{\Delta x \to 0} \frac{\Delta u}{\Delta x} \right]$$

- ❖ 편미분(partial differentiation)
 - **다변수 함수**에 대하여, 그 중 **하나의 변수**에 주목하고 나머지 변수의 값을 고정시켜 놓고 그 변수에 대해 하는 **미분**

•
$$0$$
. $f(x,y) = x^2 + xy + y^2$

$$\frac{\partial f(x,y)}{\partial x} = 2x + y$$

$$\frac{\partial f(x,y)}{\partial y} = x + 2y$$



❖ 다변수 함수의 연쇄 법칙

• f(x(t), y(t))

$$\frac{df(x(t),y(t))}{dt} = \frac{\partial f}{\partial x}\frac{dx}{dt} + \frac{\partial f}{\partial y}\frac{dy}{dt}$$

• g(x(t), y(t), z(t))

$$\frac{dg(x(t),y(t),z(t))}{dt} = \frac{\partial g}{\partial x}\frac{dx}{dt} + \frac{\partial g}{\partial y}\frac{dy}{dt} + \frac{\partial g}{\partial z}\frac{dz}{dt}$$

• 0||.
$$f(x(t), y(t)) = x(t) + 2y(t)$$

 $x(t) = 2t + 4$, $y(t) = t^2$

$$\frac{\partial f}{\partial x} = 1, \frac{\partial f}{\partial y} = 2$$
$$\frac{dx}{dt} = 2, \frac{dy}{dt} = 2t$$

$$\frac{df(x(t),y(t))}{dt} = \frac{\partial f}{\partial x}\frac{dx}{dt} + \frac{\partial f}{\partial y}\frac{dy}{dt}$$
$$= 2 + 4t$$

•
$$h(x_1(t_1, t_2, ..., t_m), x_2(t_1, t_2, ..., t_m), ..., x_n(t_1, t_2, ..., t_m))$$

$$\frac{\partial h}{\partial t_i} = \frac{\partial h}{\partial x_1} \frac{\partial x_1}{\partial t_i} + \frac{\partial h}{\partial x_2} \frac{\partial x_2}{\partial t_i} + \dots + \frac{\partial h}{\partial x_n} \frac{\partial x_n}{\partial t_i}$$

- ❖ 그레디언트(gradient)
 - 함수 f(x,y,z)의 각 변수 x,y,z에 대한 편미분을 성분으로 갖는 벡터


$$\nabla f(x, y, z) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix}$$

■ 함수 f(x,y,z)의 값이 가장 커지는 방향과 크기를 나타내는 벡터

[실습] 그레디언트 그리기

```
import numpy as np
import matplotlib.pyplot as plt
def f(x,y):
   return 2^*x^{**}2 + 4^*x^*y + 5^*y^{**}2 - 6^*x + 2^*y + 10
def dx(x,y):
   return 4*x + 4*y - 6
def dy(x,y):
   return 4*x + 10*y + 2
xi = np.linspace(-5, 20, 100)
yi = np.linspace(-6, 6, 100)
X, Y = np.meshgrid(xi, yi)
                                                 2
\mathbf{Z} = f(X,Y)
xj = np.linspace(-5, 20, 13)
yj = np.linspace(-6, 6, 7)
                                                -2
X1, Y1 = np.meshgrid(xj, yj)
                                                -4
\mathbf{Dx} = dx(X1, Y1)
\mathbf{Dy} = dy(X1, Y1)
plt.figure(figsize=(10,5))
plt.contour(X, Y, Z, levels=np.logspace(0,3,10))
plt.quiver(X1, Y1, Dx, Dy, color='red', scale=500, minshaft=4)
plt.xlabel('x')
plt.ylabel('y')
plt.show()
```


$$f(x,y) = 2x^2 + 4xy + 5y^2 - 6x + 2y + 10$$
$$\frac{\partial f(x,y)}{\partial x} = 4x + 4y - 6$$
$$\frac{\partial f(x,y)}{\partial x} = 4x + 10y + 2$$



5. 다층 퍼셉트론의 학습

❖ 다층 퍼셉트론 MLP의 학습

오차 역전파 알고리즘(Error back propagation algorithm, Backprop algorithm)



입력
$$(x_1, x_2, \dots, x_d)$$

출력 (y_1, y_2, \dots, y_m)

$$egin{aligned} osum_k &= \sum_{j=1}^p v_{kj} z_j + v_{k0} & (1 \leq k \leq m) \ & o_k &= f(osum_k) \end{aligned}$$
 $zsum_j &= \sum_{i=1}^d u_{ji} x_i + u_{j0} & (1 \leq j \leq p) \end{aligned}$


 $z_i = f(zsum_i)$

$$E = rac{1}{2} \sum_{k=1}^{m} (o_k - y_k)^2$$
 오차함수 $oldsymbol{v}^{(t+1)} = oldsymbol{v}^{(t)} - \eta rac{\partial E}{\partial oldsymbol{v}}$ $oldsymbol{u}^{(t+1)} = oldsymbol{u}^{(t)} - \eta rac{\partial E}{\partial oldsymbol{u}}$

다층 퍼셉트론의 학습

❖ 다층 퍼셉트론 MLP의 학습

오차 역전파 알고리즘(Error back propagation algorithm, Backprop algorithm)



출력
$$(y_1, y_2, \dots, y_m)$$

$$E = \frac{1}{2} \sum_{k=1}^{m} (o_k - y_k)^2 \quad \mathbf{S}$$

$$\mathbf{v}^{(t+1)} = \mathbf{v}^{(t)} - \eta \frac{\partial E}{\partial \mathbf{v}}$$

$$\mathbf{u}^{(t+1)} = \mathbf{u}^{(t)} - \eta \frac{\partial E}{\partial \mathbf{v}}$$

입력 (x_1, x_2, \dots, x_d)


$$egin{aligned} osum_k &= \sum_{j=1}^p v_{kj} z_j + v_{k0} & (1 \leq k \leq m) \\ o_k &= f(osum_k) \\ zsum_j &= \sum_{i=1}^d u_{ji} x_i + u_{j0} & (1 \leq j \leq p) \\ z_j &= f(zsum_j) \end{aligned}$$

$$\begin{split} \frac{\partial E}{\partial v_{kj}} &= \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial v_{kj}} = (o_k - t_k) f'(osum_k) z_j = \delta_k z_j \\ \frac{\partial E}{\partial u_{ji}} &= \frac{\partial E}{\partial z_j} \frac{\partial z_j}{\partial u_{ji}} = \sum_{k=1}^m \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial z_j} f'(zsum_j) x_i \\ &= \sum_{k=1}^m (o_k - t_k) f'(osum_k) v_{kj} f'(zsum_j) x_i \\ &= \sum_{k=1}^m \delta_k v_{kj} f'(zsum_j) x_i \end{split}$$

[실습] MLP 학습

```
import numpy as np
import matplotlib.pyplot as plt
class MLP:
   def init (self, hidden node=3):
       self.input node = 1; self.hidden node = hidden node; self.output node = 1
       self.w1 = np.random.rand(self.hidden_node, self.input_node)
       self.b1 = np.random.rand(self.hidden_node, 1)
                                                                                                   z1, a1
       self.w2 = np.random.rand(self.output_node, self.hidden_node)
       self.b2 = np.random.rand(self.output_node, 1)
                                                                                                               z2
   def sigmoid(self, x):
                                                                                  입력
       return 1/(1+np.exp(-x))
   def d sigmoid(self, x):
       return self.sigmoid(x)*(1-self.sigmoid(x))
   def train(self, train_x, train_y, alpha=0.1, max_iter=500):
       np.random.seed(0)
       input node = self.input node; hidden node = self.hidden node
       output_node = self.output_node; alpha = alpha; max_iter = max_iter
       for iter in range(1, max iter):
          for i in range(n_train):
             z1 = \text{np.dot}(\text{self.w1}, \text{train}_x[i].\text{reshape}(1,1)) + \text{self.b1}; \quad a1 = \text{self.sigmoid}(z1);
                                                                                                     E = \frac{1}{2}(y_i - \hat{y})^2
             z2 = \text{np.dot(self.w2, a1)} + \text{self.b2}; \quad y_{\text{hat}} = z2; \quad y_{\text{hat}} = y_{\text{hat}}
              e = 0.5*(train_y[i] - y_hat)**2; dy = -(train_y[i] - y_hat)
              dz2 = 1; dw2 = a1.T
                                                                                                      w_1 \leftarrow w_1 - \alpha \Delta w_1
              delta w2 = dy*dz2*dw2; delta b2 = dy*dz;
              da1 = self.w2.T; dz1 = self.d_sigmoid(z1); dw1 = train_x[i].T
                                                                                                      W_2 \leftarrow W_2 - \alpha \Delta W_2
              \frac{delta_w1}{delta_b1} = \frac{dy^*dz^2^*da^{1*}dz^{1*}dw^{1}}{delta_b1} = \frac{dy^*dz^{2*}da^{1*}dz^{1}}{delta_b1}
              self.w2 -= alpha*delta_w2; self.b2 -= alpha*delta_b2
              self.w1 -= alpha*delta_w1; self.b1 -= alpha *delta_b1
```

```
def predict(self, test_x):
      for i in range(n_test):
          z1 = \text{np.dot}(self.w1, \text{test}_x[i].reshape(1,1)) + self.b1
          a1 = self.sigmoid(z1)
          z2 = np.dot(self.w2, a1) + self.b2
          y hat = z2
          y_hat_list[i] = y_hat
      return y_hat_list
n train = 20
train_x = np.linspace(0, np.pi*2, n_train)
train y = np.sin(train x)
n test = 60
test_x = np.linspace(0, np.pi*2, n_test)
test_y = np.sin(test_x)
y hat list = np.zeros(n test)
mlp = MLP(hidden\_node=4)
mlp.train(train_x, train_y, max_iter=600)
plt.plot(test_x, test_y, label='ground truth')
y hat list = mlp.predict(test x)
plt.plot(test_x, y_hat_list, '-r', label='prediction')
plt.legend()
plt.show()
```



[실습] sklearn의 MLP

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import classification_report,confusion_matrix
wine = load wine()
data = pd.DataFrame(data=wine['data'], columns=wine['feature names'])
print(data.head())
                                                          alcohol malic acid ash ... hue od280/od315 of diluted wines
                                                          proline
X = wine.data
                                                            14.23
                                                             13.20
y = wine.target
                                                          2 13.16
X train, X test, y train, y test = train test split(X, y)
                                                            14.37
                                                             13.24
scaler = StandardScaler()
                                                          [5 rows x 13 columns]
scaler.fit(X train)
StandardScaler(copy=True, with_mean=True, with_std=True)
X train = scaler.transform(X train)
X test = scaler.transform(X test)
mlp = MLPClassifier(hidden_layer_sizes=(13,13,13),max_iter=500)
mlp.fit(X train,y train)
predictions = mlp.predict(X_test)
print(confusion_matrix(y_test, predictions))
print(classification report(y test, predictions))
```

import pandas as pd

from sklearn.datasets import load wine

Classes	3
Samples per class	[59,71,48]
Samples total	178
Dimensionality	13
Features	real, positive

```
[[11 0 0]
[1 15 1]
[0 \ 0 \ 17]]
                      recall f1-score support
          precision
              0.92
                       1.00
                                0.96
                                          11
              1.00
                       0.88
                               0.94
                                         17
        2
              0.94
                       1.00
                               0.97
                                         17
                                         45
                               0.96
   accuracy
                 0.95
                          0.96
                                  0.96
  macro avq
                                             45
weighted avg
                  0.96
                                   0.95
                           0.96
                                             45
```

1.71 2.43 ... 1.04

1.78 2.14 ... 1.05

2.36 2.67 ... 1.03

1.95 2.50 ... 0.86

2.59 2.87 ... 1.04

https://scikit-learn.org/

3.92 1065.0

3.40 1050.0

3.17 1185.0

3.45 1480.0

2.93 735.0

Quiz

- 1. 퍼셉트론은 선형불가 문제에 적용될 수 없다. (O,X)
- 2. 다층 퍼셉트론에서는 미분 가능한 활성화 함수를 사용하여 경사하 강법으로 학습을 한다. (O,X)
- 3. 신경망에서 기본적인 학습은 가중치를 조정하는 것을 의미한 다.(O,X)
- 4. 오차 역전파 알고리즘은 오차 함수에 대해 경사하강법을 적용하는 것으로 볼 수 있다. (O,X)